01.Data Wrangling?

데이터 랭글링(Data Wrangling)은 원천 데이터를 준비하여 분석이나 모델링에 사용할 수 있는 형태로 변환하는 과정을 말한다. 이전에는 주로 데이터 정제(cleansing)라고 하며, 정형화된 데이터를 준비하는 데 사용되던 말이다.

그러나 최근에는 비정형 데이터와 정형 데이터가 함께 사용되고 새로운 유형의 데이터가 등장함에 따라 데이터 랭글링이라는 용어가 주로 사용되고 있다. 데이터 랭글링은 데이터를 수집하고 변환하며, 결측치 처리, 이상치 제거, 데이터 포맷 변경, 변수 생성, 데이터 통합 등 다양한 작업을 포함할 수 있다.

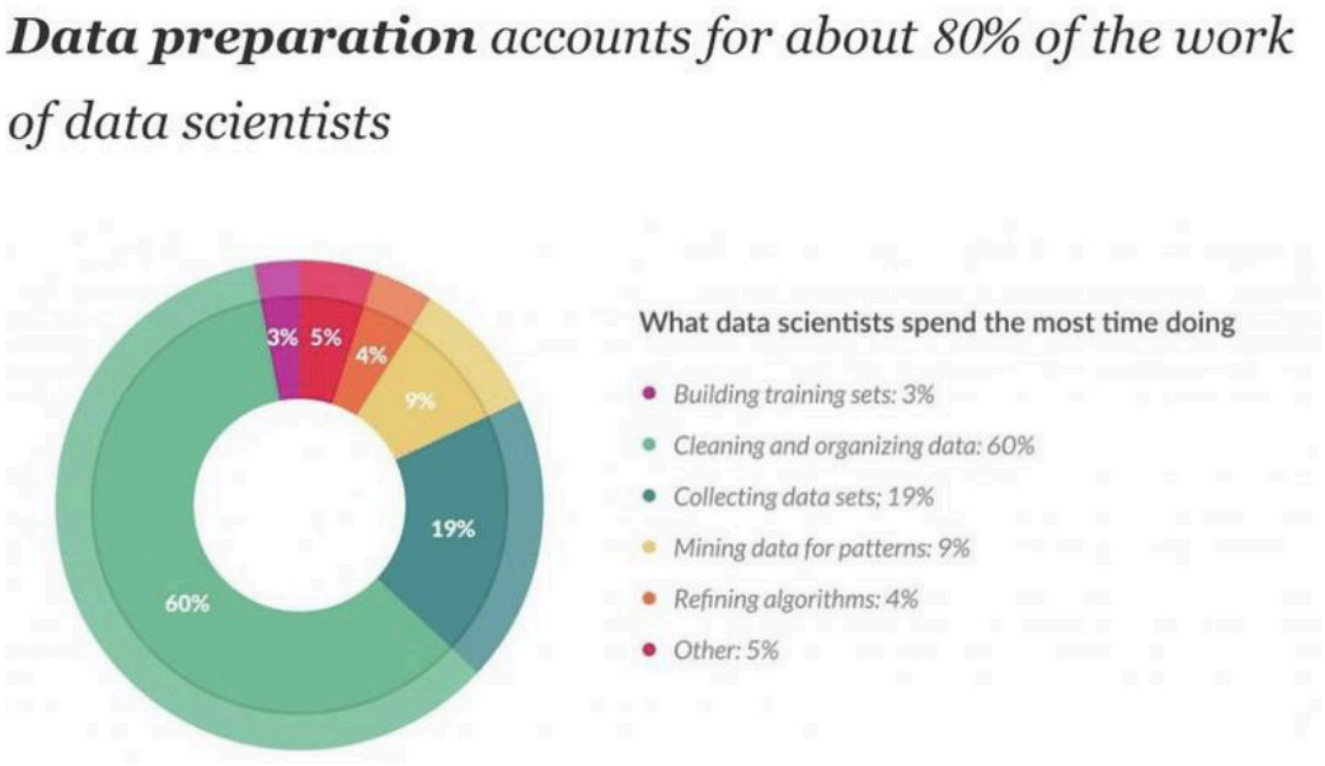

위 자료에서 볼 수 있다시피, 실제로 Data Wrangling은 data scientists들의 주요 업무 중 하나 이다.

02.Data Wrangling의 주요 단계

1.Gathering Data

파일, 데이터베이스, 웹 서버, API 등 다양한 소스에서 데이터를 수집한다.

2.Assessing Data(데이터 평가)

데이터의 품질과 구조 문제를 평가한다. 이는 데이터 불일치, 누락된 값, 재구조화 필요성을 식별하고 진단하는 것을 포함

3.Cleaning Data

평가 단계에서 식별된 문제를 해결한다. 이는 잘못된 데이터의 수정, 대체, 제거를 포함한다. 기술에는 중복 제거, 누락된 값 채우기, 오류 수정 등이 포함된다.

4.Transforming Data(데이터 변환)

분석에 더 적합하게 데이터의 형식이나 구조를 변경한다. 데이터 정규화, 데이터 스케일링, 정보 집계, 피벗 테이블 작성 등이 포함된다.

5.Enriching Data(데이터 풍부화)

다른 데이터 소스와 병합하여 데이터를 향상시키거나, 파생 속성을 추가하거나, 데이터를 더욱 정보적으로 만들기 위한 계산을 수행한다.

6.Validating and Publishing Data

데이터가 분석 목적에 맞는 기준과 표준을 충족하는지 확인한다. 일관성 검사, 품질 보증을 포함하며, 마지막으로 분석이나 보고를 위해 데이터를 사용할 수 있게 만든다.

03.실습

A.실습설명

데이터셋

실습 예제에서는 NYC weather data(뉴욕시의 일일 기상 데이터)를 사용하여 데이터 랭글링 과정을 소개한다. 데이터의 초기 상태를 이해하고, 문제점(예: 중복 값, 누락된 값, 비현실적인 값 등)을 식별하는 과정부터 시작하여, 이러한 문제를 단계별로 해결하는 방법을 설명한다.

todo

이 실습은 다음과 같은 과정을 포함한다:

- 데이터의 중복 제거
- 누락된 값과 `-inf/inf` 값의 처리
- 데이터의 정제와 풍부화
- 최종적으로 클리닝된 데이터셋의 구성

데이터 정보

YC weather data에는 아래와 같은 정보가 포함되어있다.

- PRCP: 강수량(밀리미터)
- SNOW: 강설량(밀리미터)
- SNWD: 적설량(밀리미터)
- TMAX: 일일 최고 온도(섭씨)
- TMIN: 일일 최저 온도(섭씨)
- TOBS: 관측 시점의 온도(섭씨)
- WESF: 눈 속의 물량(밀리미터)

데이터 외부 정보

데이터를 파악하기 위한 외부 정보는 아래와 같다.

- 미국 국립기상청에 따르면, 1934년 2월 9일에 중앙 공원에서 기록된 가장 낮은 온도는 -15°F (-26.1°C)였다.
- 태양의 광구(photosphere)의 온도는 대략 5,505°C이다.

> -26.1°C보다 낮거나 5,505°C보다 높으면 데이터가 이상이 있음을 알 수 있다.

B.실습

주요 코드

01.Understanding data

df = pd.read_csv('data/MDA_04_dirty_data.csv') print(df.head()) print(df.describe()) print(df.info())

```
![](https://velog.velcdn.com/images/kms39273/post/39b1a763-a5b1-4b1b-a929-a0da7023418f/

특히, df.info를 통해 정재할 null값에 대해 알 수 있다.

#### 02. Understanding Nulls-1
>```python
print(df[df.WESF.isna()==False])
```

'WESF' 열에서 결측치가 아닌 행들만을 출력한다.

03. Understanding Nulls :2

contain_nulls = df[df.SNOW.isna() | df.SNWD.isna() | df.TOBS.isna() | df.WESF.isna() | df.inclement_weather.isna()] print(contain_nulls.shape[0]) print(contain_nulls.head(10))

```
어느 열이라도 결측치를 포함하는 행들을 확인하고 그 수를 세는 데 사용. 이는 결측치 처리 전에 더

#### 04. Understanding inf/-inf :1
>```python
def get_inf_count(df):
return {
col: df[df[col].isin([np.inf, -np.inf])].shape[0] for col in df.columns
}
print(get_inf_count(df))
```

각 열에서 무한대 값을 포함하는 행의 수를 출력

05. Understanding inf/-inf :2

snow = pd.DataFrame({ 'np.inf Snow Depth': df[df.SNWD == np.inf].SNOW.describe(), '-np.inf Snow Depth': df[df.SNWD == -np.inf].SNOW.describe() }) print(snow)

'SNWD' 열의 값이 무한대 또는 음의 무한대인 행들의 'SNOW' 열의 분포를 이해하는 데 사용

06. Understanding ‘data’ and ‘station’ :object
>```python
print(df.describe(include='object’))

describe() 함수는 기본적으로 수치형 열에 대한 요약 정보를 제공. include 매개변수를 사용하여 특정 데이터 타입의 열에 대한 정보를 요청할 수 있다. 여기서 'object'는 문자열 열을 의미 문자열 열에 대한 describe() 함수의 출력은 다음을 포함한다.

- count: 결측치를 제외한 행의 수
- unique: 고유한 값의 수
- top: 가장 자주 등장하는 값
- freq: 가장 자주 등장하는 값의 빈도

06. Understanding ‘data’ and ‘station’ :Duplication information

print(df[df.duplicated(keep=False)].head(10))

이 코드는 데이터프레임 `df`에서 중복된 행을 찾아 그 중 처음 10개를 출력
- `df.duplicated(keep=False)`: 이는 `df` 데이터프레임에서 중복된 행을 찾는다. `duplicated(
- `keep=False` 매개변수는 모든 중복 행을 True로 표시하도록 설정합니다. 즉, 첫 번째 중복 행만
- `df[df.duplicated(keep=False)]`: 위에서 얻은 불리언 시리즈를 사용하여 중복된 행만 선택. (

06. Data Wrangling
>```python
# 1. make the date a datetime (We don't need time (hour/minutes…) information.)
df.date = pd.to_datetime(df.date)
# 2. save the WEST information
station_qm_wesf = df[df.station == '?'].drop_duplicates('date').set_index('date').WESF
# 3. sort ‘?’ to the bottom
df.sort_values('station', ascending=False, inplace=True)
# 4. drop duplicates based on the date column keeping the first occurrence
# which will be the valid station if it has data
df_deduped = df.drop_duplicates('date’)
# 5. remove the station column because we are done with it
df_deduped = df_deduped.drop(columns='station').set_index('date').sort_index()
# 6. Insert the saved WESF value.
# combine_first(): Combine two DataFrame objects by filling null values in one DataFram
df_deduped = df_deduped.assign(
WESF=lambda x: x.WESF.combine_first(station_qm_wesf)
)
print(df_deduped.shape)

1. df.date = pd.to_datetime(df.date): 'date' 열의 데이터 타입을 datetime으로 변환
2. station_qm_wesf = df[df.station == '?'].drop_duplicates('date').set_index('date').WESF: 'station' 열이 '?'인 행들을 선택하고, 이 중 'date'에 대해 중복되는 행들을 제거 그 후 'date' 열을 인덱스로 설정하고, 'WESF' 열만 남긴다. 이를 station_qm_wesf에 저장

3. `df.sort_values('station', ascending=False, inplace=True)`: 'station' 열을 기준으로 데이터프레임을 내림차순으로 정렬. 이렇게 하면 'station' 값이 '?'인 행들이 데이터프레임의 아래쪽으로 이동한다.

- `ascending=False`: 이 파라미터는 정렬 방식을 내림차순으로 정렬('station' 열을 기준으로 내림차순으로 데이터프레임을 정렬)
- `inplace=True`: `inplace=True`이면 새로운 데이터프레임을 생성하는 것이 아닌, 원래의 데이터프레임이 정렬된 상태로 바뀐다.

4. `df_deduped = df.drop_duplicates('date')`: 'date' 열을 기준으로 중복된 행들을 제거. 중복된 경우 첫 번째 행만 남기게 된다. 이렇게 생성된 새로운 데이터프레임을 `df_deduped`에 저장
5. `df_deduped = df_deduped.drop(columns='station').set_index('date').sort_index()`: 'station' 열을 제거하고, 'date' 열을 인덱스로 설정한 후 인덱스를 기준으로 정렬
6. `df_deduped = df_deduped.assign(WESF=lambda x: x.WESF.combine_first(station_qm_wesf))`: `df_deduped`의 'WESF' 열에 결측치가 있을 경우, 이전에 저장한 `station_qm_wesf`의 값을 사용하여 결측치를 채운다. `combine_first()` 함수는 첫 번째 데이터프레임의 결측치를 두 번째 데이터프레임의 값으로 채워준다.
7. `print(df_deduped.shape)`: 최종적으로 수정된 데이터프레임 `df_deduped`의 형태(행과 열의 수)를 출력

07.Handling nulls - Remove

print(df_deduped.dropna().shape) df_deduped =df_deduped.dropna(thresh=df_deduped.shape[1] * .80) print(df_deduped) df_deduped =df_deduped.dropna(how='all', subset=['inclement_weather', 'SNOW', 'SNWD']) print(df_deduped) df_deduped =df_deduped.dropna(how='all') print(df_deduped.shape)

1. `print(df_deduped.dropna().shape)`: `dropna()` 함수는 결측치를 포함하는 모든 행을 삭제
2. `df_deduped = df_deduped.dropna(thresh=df_deduped.shape[1] * .80)`: `dropna(thresh=r
3. `df_deduped = df_deduped.dropna(how='all', subset=['inclement_weather', 'SNOW', 'SNW
4. `df_deduped = df_deduped.dropna(how='all')`: `dropna(how='all')` 함수는 모든 열의 값이

08.Handling nulls - Fill

```python
print(df_deduped['WESF'].fillna(0, inplace=True))
print(df_deduped)
df_deduped=df_deduped.assign(
TMAX=lambda x: x.TMAX.fillna(method='ffill'), #backward fill : 'bfill'
TMIN=lambda x: x.TMIN.fillna(method='ffill')
)
print(df_deduped)
df_deduped=df_deduped.assign(
SNWD=lambda x: x.SNWD.clip(0, x.SNOW)
)
print(df_deduped)
```

1. `print(df_deduped['WESF'].fillna(0, inplace=True))`와 `print(df_deduped)`: `fillna(0, inplace=True)` 함수는 'WESF' 열의 결측치를 0으로 바꿉니다. `inplace=True`는 이 변경사항을 원래의 데이터프레임에 바로 적용합니다. 그런데 `fillna()` 함수는 반환값이 없다는 점에 주의해야 합니다. 따라

서 첫 번째 `print()` 함수는 아마도 None을 출력할 것입니다. 두 번째 `print()` 함수는 변경된 데이터프레임을 출력합니다.

2. `df_deduped=df_deduped.assign(TMAX=lambda x: x.TMAX.fillna(method='ffill'), TMIN=lambda x: x.TMIN.fillna(method='ffill'))`와 `print(df_deduped)`: `assign()` 함수는 새로운 열을 추가하거나 기존 열을 수정합니다. 여기서는 'TMAX'와 'TMIN' 열의 결측치를 이전 행의 값으로 채웁니다 (`method='ffill'`은 forward fill을 의미합니다). 그런데 'backward fill'에 대한 주석이 있으므로, 이전 행 대신 다음 행의 값으로 채우려면 `method='bfill'`을 사용하면 됩니다. 변경된 데이터프레임을 출력합니다.
3. `df_deduped=df_deduped.assign(SNWD=lambda x: x.SNWD.clip(0, x.SNOW))`와 `print(df_deduped)`: `clip()` 함수는 값의 범위를 제한합니다. 여기서는 'SNWD' 열의 값이 0 이하이면 0으로, 'SNOW' 열의 값 이상이면 'SNOW' 열의 값으로 바꿉니다. 즉, 'SNWD'의 값은 0과 'SNOW' 사이에 있어야 합니다. 변경된 데이터프레임을 출력합니다.

09.Handling nulls - Impute

df_deduped=df_deduped.assign(TMAX=lambda x: x.TMAX.fillna(x.TMAX.median()), TMIN=lambda x: x.TMIN.fillna(x.TMIN.median()), #average of TMAX and TMIN TOBS=lambda x: x.TOBS.fillna((x.TMAX + x.TMIN) / 2)) print(df_deduped) print(df_deduped.head(10)) df_deduped=df_deduped.reindex(pd.date_range('2018-01-01', '2018-12-31', freq='D')).apply(lambda x: x.interpolate()) print(df_deduped.head(10))

1. `df_deduped=df_deduped.assign(TMAX=lambda x: x.TMAX.fillna(x.TMAX.median()), TMIN=la
2. `print(df_deduped.head(10))`, `df_deduped=df_deduped.reindex(pd.date_range('2018-01-

10.lambda
`lambda`는 Python에서 익명 함수(anonymous function)를 생성하는 키워드입니다. 이는 이름 없이
```python
lambda arguments: expression
```

`arguments`는 함수의 입력값이며, `expression`은 `arguments`를 사용하여 계산한 결과값입니다. 위의 코드에서 `lambda`는 `assign()` 함수와 `apply()` 함수에 사용되었습니다:

- `assign()` 함수에서는 `lambda`를 사용하여 각 열에 대한 동작을 정의하였습니다. 예를 들어, `TMAX=lambda x: x.TMAX.fillna(x.TMAX.median())`는 'TMAX' 열의 결측치를 해당 열의 중앙값으로 채우는 동작을 정의하였습니다. 여기서 `x`는 데이터프레임을 의미합니다.
- `apply()` 함수에서는 `lambda`를 사용하여 각 열에 대해 `interpolate()` 함수를 적용하였습니다. 여기서 `x`는 각 열을 의미합니다. `lambda` 함수는 코드를 간결하게 만들어 주며, 특히 함수를 다른 함수의 인자로 전달할 때 유용합니다.

전체 코드

```
pd.set_option('display.max_columns', None)
df = pd.read_csv("/content/drive/MyDrive/MDA_05_dirty_data.csv")
df.head()

# Understanding data - describe()
print(df.describe())

# Understanding data - info()
print(df.info())

# Understanding Nulls : (1) WESF has only 11 non-null values: how do they look like?
print(df[df.WESF.isna()==False])

# Understanding Nulls : (2) How many entries have at least one null value?
contain_nulls = df[
df.SNOW.isna() | df.SNWD.isna() | df.TOBS.isna()
| df.WESF.isna() | df.inclement_weather.isna()
]
print(contain_nulls.shape[0])
print(contain_nulls.head(10))


# Understanding inf/-inf: (1) Find the number of inf/-inf values per column in the df
def get_inf_count(df):
    return {
    col: df[df[col].isin([np.inf, -np.inf])].shape[0] for col in df.columns
    }
print(get_inf_count(df))

# Understanding inf/-inf: (2) Take a deep look at the 'SNWD(Snow depth)'
# Since snow depth (SNWD) and snowfall amount (SNOW) are closely related, let's interpr
snow = pd.DataFrame({
'np.inf Snow Depth': df[df.SNWD == np.inf].SNOW.describe(),
'-np.inf Snow Depth': df[df.SNWD == -np.inf].SNOW.describe()
})
print(snow)

# Understanding 'data' and 'station'
print(df.describe(include='object'))

# Understanding 'data' and 'station' : Duplication information
print(df[df.duplicated(keep=False)].head(10))
# default는 keep=True
# 그러면 중복값 중 첫째  값은 안나온다.
# 이렇게 확인할 때에는 첫번째 행을 킵 없이!!!!



# Understanding 'data' and 'station' : Unique value of the station whose WESF value is
print(df[df.WESF.notna()].station.unique())

# 1. make the date a datetime (We don't need time (hour/minutes…) information.)
df.date = pd.to_datetime(df.date)
# 2. save the WEST information
station_qm_wesf = df[df.station == '?'].drop_duplicates('date').set_index('date').WESF
# 3. sort '?' to the bottom
df.sort_values('station', ascending=False, inplace=True)
# 4. drop duplicates based on the date column keeping the first occurrence
# which will be the valid station if it has data
df_deduped = df.drop_duplicates('date')
```

```
# 5. remove the station column because we are done with it
df_deduped = df_deduped.drop(columns='station').set_index('date').sort_index()
# 6. Insert the saved WESF value.
# combine_first(): Combine two DataFrame objects by filling null values in one DataFram
df_deduped = df_deduped.assign(
WESF=lambda x: x.WESF.combine_first(station_qm_wesf)
)
print(df_deduped.shape)
```